Problem Sheet 1 – Lösung

Part 1

1a) Regressionsproblem

Features X und Label Y mit jeweiligen Raum:

$$\begin{aligned} X &= (U_1, U_2, \ldots, U_N), & X &\in (0,\infty)^N, \\ Y &= L, & Y &\in (0,\infty), \\ Z &= X \times Y, & Z &= (X,Y) \sim P_L. \end{aligned}$$

Dabei besteht die Ausgabe X aus N unabhängig und identisch verteilten Zufallsvariablen mit $U_i \sim \text{Uniform}(0, L)$.

Für den quadratischen Verlust gilt

$$\ell(h(x), y) = (h(x) - y)^2.$$

Das Populationsrisiko lautet

$$\begin{aligned} \mathcal{R}_L(h) &= \mathbb{E}\big[(h(X) - Y)^2\big] \\ &= \mathbb{E}\big[(h(U_1, \ldots, U_N) - L)^2\big]. \end{aligned}$$

1b) Populationsrisiko der Hypothesen

(1) h_1 Es sei

$$h_1(U) = \frac{2}{N}\sum_{i=1}^{N} U_i, \qquad \mathbb{E}(U_i) = \frac{L}{2}, \qquad \text{Var}(U_i) = \frac{L^2}{12}.$$

Dann gilt

$$\mathbb{E}[h_1(U)] = \frac{2}{N}\sum_{i=1}^{N}\mathbb{E}(U_i) = \frac{2}{N}\cdot N \cdot \frac{L}{2} = L.$$

Da h_1 erwartungstreu ($= L$) ist, entspricht das Risiko der Varianz:

$$\begin{aligned} \mathcal{R}_L(h_1) &= \text{Var}(h_1(U)) \\ &= \frac{4}{N^2}\,\text{Var}\Big(\sum_{i=1}^{N} U_i\Big) \\ &= \frac{4}{N^2}\sum_{i=1}^{N}\text{Var}(U_i) \\ &= \frac{4}{N^2}\cdot N \cdot \frac{L^2}{12} = \boxed{\frac{L^2}{3N}}. \end{aligned}$$

Für $N = 10$ ergibt sich

$$\boxed{\mathcal{R}_L(h_1) = \frac{L^2}{30}}.$$

(2) h_2 Setze

$$h_2(U) = M \qquad M = \max_{1 \le i \le N} U_i,$$

Damit folgt

$$\begin{aligned}\mathcal{R}_L(h_2) &= \mathbb{E}[(M-L)^2] \\ &= \mathbb{E}(M^2) - 2L\mathbb{E}(M) + L^2.\end{aligned}$$

Das Maximum ist höchstens t, wenn jede einzelne Beobachtung höchstens t ist. Also für eine Beobachtung

$$\Pr(U_i \le t) = \frac{t}{L} \quad (0 \le t \le L).$$

Für alle Beobachtungen

$$F_M(t) = \Pr(M \le t) = \left(\frac{t}{L}\right)^N \quad (0 \le t \le L).$$

Ableiten der Verteilungsfunktion F_M ergibt die Dichte

$$f_M(t) = F_M'(t) = \frac{Nt^{N-1}}{L^N}, \qquad (0 \le t \le L).$$

Zur Risikoberechnung werden $\mathbb{E}(M)$ und $\mathbb{E}(M^2)$ (siehe ausmultiplizierte Loss-Funktion) benötigt:

$$\begin{aligned}\mathbb{E}(M) &= \int_0^L t f_M(t)\,dt = \frac{N}{L^N}\int_0^L t^N\,dt = \frac{N}{L^N}\cdot\frac{L^{N+1}}{N+1} = \frac{N}{N+1}L, \\ \mathbb{E}(M^2) &= \int_0^L t^2 f_M(t)\,dt = \frac{N}{L^N}\int_0^L t^{N+1}\,dt = \frac{N}{L^N}\cdot\frac{L^{N+2}}{N+2} = \frac{N}{N+2}L^2.\end{aligned}$$

Daraus folgt

$$\begin{aligned}\mathcal{R}_L(h_2) &= \frac{N}{N+2}L^2 - 2L\frac{N}{N+1}L + L^2 \\ &= L^2\left(\frac{N}{N+2} - \frac{2N}{N+1} + 1\right) = \boxed{\frac{2L^2}{(N+1)(N+2)}}.\end{aligned}$$

Für $N = 10$ gilt

$$\boxed{\mathcal{R}_L(h_2) = \frac{2L^2}{11 \cdot 12} = \frac{L^2}{66}}.$$

(3) h_3 Setze

$$h_3(U) = \frac{N+1}{N}M \qquad M = \max_{1 \le i \le N} U_i,$$

Wie bereits berechnet, gelten

$$\mathbb{E}(M) = \frac{N}{N+1}L, \qquad \mathbb{E}(M^2) = \frac{N}{N+2}L^2.$$

Damit

$$\mathbb{E}[h_3(U)] = \frac{N+1}{N}\mathbb{E}(M) = \frac{N+1}{N}\cdot\frac{N}{N+1}L = L.$$

h_3 ist erwartungstreu, weshalb

$$\mathcal{R}_L(h_3) = \mathrm{Var}(h_3(U)).$$

Zunächst ergibt sich

$$\begin{aligned}\mathrm{Var}(M) &= \mathbb{E}(M^2) - [\mathbb{E}(M)]^2 \\ &= \frac{N}{N+2}L^2 - \frac{N^2}{(N+1)^2}L^2 \\ &= \frac{NL^2}{(N+2)(N+1)^2}.\end{aligned}$$

Mit $\mathrm{Var}(aM) = a^2\,\mathrm{Var}(M)$ folgt

$$\begin{aligned}\mathcal{R}_L(h_3) &= \left(\frac{N+1}{N}\right)^2 \mathrm{Var}(M) \\ &= \left(\frac{N+1}{N}\right)^2 \frac{NL^2}{(N+2)(N+1)^2} = \boxed{\frac{L^2}{N(N+2)}}.\end{aligned}$$

Für $N = 10$ gilt

$$\boxed{\mathcal{R}_L(h_3) = \frac{L^2}{10 \cdot 12} = \frac{L^2}{120}}.$$

Somit gilt für $N = 10$:

$$\boxed{\mathcal{R}_L(h_3) = \frac{L^2}{120} \le \mathcal{R}_L(h_2) = \frac{L^2}{66} \le \mathcal{R}_L(h_1) = \frac{L^2}{30}}$$

Part 2

2a) Problemstellung

$$X = (U_1, U_2, \ldots, U_{10}), \qquad X \in [1,5]^{10}, \qquad Y = L, \qquad Y \in [1,5].$$

Hier ist $L \sim \mathrm{Uniform}[1,5]$, und bedingt auf L gilt $U_i \sim \mathrm{Uniform}[0,L]$. Somit

$$Z = X \times Y, \qquad (X,Y) \sim P, \qquad \ell(h(x),y) = (h(x)-y)^2.$$

2b) Erwartetes Risiko

Für $N = 10$ wurden in Teil 1 die bedingten Risiken berechnet:

$$\mathcal{R}_L(h_1) = \frac{L^2}{30}, \qquad \mathcal{R}_L(h_2) = \frac{L^2}{66}, \qquad \mathcal{R}_L(h_3) = \frac{L^2}{120}.$$

Nun wird auch über die Zufallsvariable L gemittelt:

$$\begin{aligned}\mathcal{R}(h) &= \mathbb{E}\big[\mathbb{E}[(h(U)-L)^2 \mid L]\big] \\ &= \mathbb{E}_L[\mathcal{R}_L(h)].\end{aligned}$$

Da $L \sim \mathrm{Uniform}[1,5]$, gilt

$$\mathbb{E}(L^2) = \frac{1}{4}\int_1^5 l^2\,dl = \frac{1}{4}\cdot\frac{125-1}{3} = \frac{31}{3}.$$

Damit ergeben sich

$$\begin{aligned}\mathcal{R}(h_1) &= \frac{1}{30}\cdot\frac{31}{3} = \frac{31}{90}, \\ \mathcal{R}(h_2) &= \frac{1}{66}\cdot\frac{31}{3} = \frac{31}{198}, \\ \mathcal{R}(h_3) &= \frac{1}{120}\cdot\frac{31}{3} = \frac{31}{360}.\end{aligned}$$

Also

$$\boxed{\mathcal{R}(h_3) < \mathcal{R}(h_2) < \mathcal{R}(h_1)}.$$

2c) Stichprobe und empirisches Risiko

Es sei

$$L_i \sim \text{Uniform}[1,5], \qquad U_{i,1},\dots,U_{i,10} \mid L_i \overset{\text{iid}}{\sim} \text{Uniform}[0,L_i].$$

Weiterhin

$$X_i = (U_{i,1},\dots,U_{i,10}), \qquad Y_i = L_i.$$

Dabei bezeichnet m die Anzahl unabhängig erzeugter gelabelter Beispiele; $N = 10$ ist die Anzahl der Beobachtungen innerhalb eines Eingabevektors. Die Stichprobe lautet

$$D_m = \big((X_1,Y_1),\dots,(X_m,Y_m)\big) \sim P^{\otimes m}.$$

Für eine Hypothese $h\colon X \to Y$ ist das empirische Risiko

$$\begin{aligned}\widehat{\mathcal{R}}_m(h) &= \frac{1}{m}\sum_{i=1}^{m}\big(h(X_i)-Y_i\big)^2 \\ &= \frac{1}{m}\sum_{i=1}^{m}\big(h(U_{i,1},\dots,U_{i,10})-L_i\big)^2.\end{aligned}$$